

Métodos numéricos para ingenieros

QUINTA EDICIÓN

Mc
Graw
Hill

Steven C. Chapra
Raymond P. Canale

CAPÍTULO 17

Regresión por mínimos cuadrados

Cuando los datos tienen errores sustanciales, la interpolación polinomial es inapropiada y puede dar resultados poco satisfactorios cuando se utiliza para predecir valores intermedios. Con frecuencia los datos experimentales son de este tipo. Por ejemplo, en la figura 17.1a se muestran siete datos obtenidos experimentalmente que presentan una variabilidad significativa. Una inspección visual de esos datos sugiere una posible relación entre y y x . Es decir, la tendencia general indica que valores altos de y están asociados con valores altos de x . Ahora, si un polinomio de interpolación de sexto grado se ajusta a estos datos (figura 17.1b), pasará exactamente a través de todos los puntos. Sin embargo, a causa de la variabilidad en los datos, la curva oscila mucho en el intervalo entre los puntos. En particular, los valores interpolados para $x = 1.5$ y $x = 6.5$ parecen estar bastante más allá del rango sugerido por los datos.

Una estrategia más apropiada en tales casos consiste en obtener una función de aproximación que se ajuste a la forma o a la tendencia general de los datos, sin coincidir necesariamente en todos los puntos. La figura 17.1c ilustra cómo se utiliza una línea recta para caracterizar de manera general la tendencia de los datos sin pasar a través de algún punto específico.


Una manera para determinar la línea de la figura 17.1c es inspeccionar en forma visual los datos graficados y después trazar una “mejor” línea a través de los puntos. Aunque tales procedimientos “a ojo” apelan al sentido común y son válidos para cálculos “superficiales”, resultan deficientes por ser arbitrarios. Es decir, a menos que los puntos definan una línea recta perfecta (en cuyo caso la interpolación resultaría apropiada), diferentes analistas dibujarían líneas distintas.

Para dejar a un lado dicha subjetividad se debe encontrar algún criterio para establecer una base para el ajuste. Una forma de hacerlo es obtener una curva que minimice la discrepancia entre los puntos y la curva. Una técnica para lograr tal objetivo, llamada *regresión por mínimos cuadrados*, se analizará en este capítulo.

17.1 REGRESIÓN LINEAL

El ejemplo más simple de una aproximación por mínimos cuadrados es ajustar una línea recta a un conjunto de observaciones definidas por puntos: $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$. La expresión matemática para la línea recta es

$$y = a_0 + a_1x + e \quad (17.1)$$

**FIGURA 17.1**

a) Datos que muestran un error significativo. b) Ajuste polinomial oscilando más allá del rango de los datos. c) Resultados más satisfactorios mediante el ajuste por mínimos cuadrados.

donde a_0 y a_1 son coeficientes que representan la intersección con el eje y y la pendiente, respectivamente, e es el error, o diferencia, entre el modelo y las observaciones, el cual se representa al reordenar la ecuación (17.1) como

$$e = y - a_0 - a_1x$$

Así, el *error* o *residuo* es la discrepancia entre el valor verdadero de y y el valor aproximado, $a_0 + a_1x$, que predijo la ecuación lineal.

17.1.1 Criterio para un “mejor” ajuste


Una estrategia para ajustar una “mejor” línea a través de los datos será minimizar la suma de los errores residuales de todos los datos disponibles, como sigue:

$$\sum_{i=1}^n e_i = \sum_{i=1}^n (y_i - a_0 - a_1 x_i) \quad (17.2)$$

donde n = número total de puntos. Sin embargo, éste es un criterio inadecuado, como lo muestra la figura 17.2a, la cual presenta el ajuste de una línea recta de dos puntos. Obviamente, el mejor ajuste es la línea que une los puntos. Sin embargo, cualquier línea

FIGURA 17.2

Ejemplo de algunos criterios para “el mejor ajuste” que son inadecuados para la regresión: a) minimizar la suma de los residuos, b) minimizar la suma de los valores absolutos de los residuos y c) minimizar el error máximo de cualquier punto individual.



recta que pase a través del punto medio que une la línea (excepto una línea perfectamente vertical) da como resultado un valor mínimo de la ecuación (17.2) igual a cero, debido a que los errores se cancelan.

Por lo tanto, otro criterio lógico podría ser minimizar la suma de los valores absolutos de las discrepancias,

$$\sum_{i=1}^n |e_i| = \sum_{i=1}^n |y_i - a_0 - a_1 x_i|$$

La figura 17.2b muestra por qué este criterio también es inadecuado. Para los cuatro puntos dados, cualquier línea recta que esté dentro de las líneas punteadas minimizará el valor absoluto de la suma. Así, este criterio tampoco dará un único mejor ajuste.

Una tercera estrategia para ajustar una mejor línea es el criterio *minimax*. En esta técnica, la línea se elige de manera que minimice la máxima distancia a que un punto se encuentra de la línea. Como se ilustra en la figura 17.2c, tal estrategia es inadecuada para la regresión, ya que da excesiva influencia a puntos fuera del conjunto; es decir, a un solo punto con un gran error. Deberá observarse que el principio minimax es, en algunas ocasiones, adecuado para ajustar una función simple a una función complicada (Carnahan, Luther y Wilkes, 1969).

La estrategia que supera las deficiencias de los procedimientos mencionados consiste en minimizar la suma de los cuadrados de los residuos entre la y medida y la y calculada con el modelo lineal

$$S_r = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_{i,\text{medida}} - y_{i,\text{modelo}})^2 = \sum_{i=1}^n (y_i - a_0 - a_1 x_i)^2 \quad (17.3)$$

Este criterio tiene varias ventajas, entre ellas el hecho de que se obtiene una línea única para cierto conjunto de datos. Antes de analizar tales propiedades, presentaremos una técnica para determinar los valores de a_0 y a_1 que minimizan la ecuación (17.3).

17.1.2 Ajuste de una línea recta por mínimos cuadrados

Para determinar los valores de a_0 y a_1 , la ecuación (17.3) se deriva con respecto a cada uno de los coeficientes:

$$\begin{aligned} \frac{\partial S_r}{\partial a_0} &= -2 \sum (y_i - a_0 - a_1 x_i) \\ \frac{\partial S_r}{\partial a_1} &= -2 \sum [(y_i - a_0 - a_1 x_i) x_i] \end{aligned}$$

Observe que hemos simplificado los símbolos de la sumatoria; a menos que se indique otra cosa, todas las sumatorias van desde $i = 1$ hasta n . Al igualar estas derivadas a cero, se dará como resultado un S_r mínimo. Si se hace esto, las ecuaciones se expresan como

$$\begin{aligned} 0 &= \sum y_i - \sum a_0 - \sum a_1 x_i \\ 0 &= \sum y_i x_i - \sum a_0 x_i - \sum a_1 x_i^2 \end{aligned}$$

Ahora, si observamos que $\sum a_0 = na_0$, expresamos las ecuaciones como un conjunto de dos ecuaciones lineales simultáneas, con dos incógnitas (a_0 y a_1):

$$na_0 + \left(\sum x_i\right)a_1 = \sum y_i \quad (17.4)$$

$$\left(\sum x_i\right)a_0 + \left(\sum x_i^2\right)a_1 = \sum x_i y_i \quad (17.5)$$

Éstas se llaman *ecuaciones normales*, y se resuelven en forma simultánea

$$a_1 = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{n \sum x_i^2 - (\sum x_i)^2} \quad (17.6)$$

Este resultado se utiliza conjuntamente con la ecuación (17.4) para obtener

$$a_0 = \bar{y} - a_1 \bar{x} \quad (17.7)$$

donde $\bar{y}$ y $\bar{x}$ son las medias de y y x , respectivamente.

EJEMPLO 17.1 Regresión lineal

Planteamiento del problema. Ajuste a una línea recta los valores x y y en las dos primeras columnas de la tabla 17.1.

Solución. Se calculan las siguientes cantidades:

$$\begin{aligned} n &= 7 & \sum x_i y_i &= 119.5 & \sum x_i^2 &= 140 \\ \sum x_i &= 28 & \bar{x} &= \frac{28}{7} = 4 \\ \sum y_i &= 24 & \bar{y} &= \frac{24}{7} = 3.428571 \end{aligned}$$

Mediante las ecuaciones (17.6) y (17.7)

$$a_1 = \frac{7(119.5) - 28(24)}{7(140) - (28)^2} = 0.8392857$$

$$a_0 = 3.428571 - 0.8392857(4) = 0.07142857$$

TABLA 17.1 Cálculos para el análisis de error en el ajuste lineal.

x_i	y_i	$(y_i - \bar{y})^2$	$(y_i - a_0 - a_1 x_i)^2$
1	0.5	8.5765	0.1687
2	2.5	0.8622	0.5625
3	2.0	2.0408	0.3473
4	4.0	0.3265	0.3265
5	3.5	0.0051	0.5896
6	6.0	6.6122	0.7972
7	5.5	4.2908	0.1993
Σ	24.0	22.7143	2.9911

Por lo tanto, el ajuste por mínimos cuadrados es

$$y = 0.07142857 + 0.8392857x$$

La línea, junto con los datos, se muestran en la figura 17.1c.

17.1.3 Cuantificación del error en la regresión lineal

Cualquier otra línea diferente a la calculada en el ejemplo 17.1 dará como resultado una suma mayor de los cuadrados de los residuos. Así, la línea es única y, en términos de nuestro criterio elegido, es la “mejor” línea a través de los puntos. Varias propiedades de este ajuste se observan al examinar más de cerca la forma en que se calcularon los residuos. Recuerde que la suma de los cuadrados se define como [ecuación (17.3)]

$$S_r = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - a_0 - a_1 x_i)^2 \quad (17.8)$$

Observe la similitud entre las ecuaciones (PT5.3) y (17.8). En el primer caso, el cuadrado del residuo representa el cuadrado de la discrepancia entre el dato y una estimación de la medida de tendencia central: la media. En la ecuación (17.8), el cuadrado del residuo representa el cuadrado de la distancia vertical entre el dato y otra medida de tendencia central: la línea recta (figura 17.3).

La analogía se puede extender aún más en casos donde 1. la dispersión de los puntos alrededor de la línea es de magnitud similar en todo el rango de los datos, y 2. la distribución de estos puntos cerca de la línea es normal. Es posible demostrar que si estos criterios se cumplen, la regresión por mínimos cuadrados proporcionará la mejor (es decir, la más adecuada) estimación de a_0 y a_1 (Draper y Smith, 1981). Esto se conoce en

FIGURA 17.3

El residuo en la regresión lineal representa la distancia vertical entre un dato y la línea recta.

